

分类号: TM391

单位代码: 10335

密 级: 公开

学 号: 21432041

浙江大学

硕 士 学 位 论 文



论文题目 基于 KECA 的非线性故障检测

作者姓名 秦家祥

指导教师 杨春节 教授

学科 (专业) 控制科学与工程学

所在学院 控制科学与工程学院

提交日期 二〇一六年十二月五二十六日

A Dissertation Submitted to Zhejiang
University for the Degree of
Master of Engineering



TITLE: Nonlinear Fault Detection Based on KECA

Author: Jiaxiang Qin

Supervisor: Prof. Chunjie Yang Supervisor

Subject: Control Science and Engineering

College: College of Control Science and Engineering

Submitted Date: 2016-12-26

基于 KECA 的非线性故障检测



论文作者签名: _____

指导教师签名: _____

论文评阅人 1: _____ 匿名评审

评阅人 2: _____ 匿名评审

评阅人 3: _____ 匿名评审

评阅人 4: _____

评阅人 5: _____

答辩委员会主席: _____

委员 1: _____

委员 2: _____

委员 3: _____

委员 4: _____

委员 5: _____

答辩日期: _____ 2017-03-10

Nonlinear Fault Detection Based on KECA



Author's signature: _____

Supervisor's signature: _____

Thesis Reviewers 1: _____ anonymous reviewer

Reviewers 2: _____ anonymous reviewer

Reviewers 3: _____ anonymous reviewer

Reviewers 4: _____

Reviewers 5: _____

Committee Chairperson: _____

Committeeman 1: _____

Committeeman 2: _____

Committeeman 3: _____

Committeeman 4: _____

Committeeman 5: _____

Date of oral defence: _____ 2017-03-10

目录

第 1 章 基于集成学习和贝叶斯推论的改进核熵成分分析 1

1.1 引言 1

1.2 基于集成学习和贝叶斯网络的模型 2

1.2.1 KECA 模型介绍 2

1.2.2 KECA 的优势 4

1.2.3 基于 KECA 的非线性过程监测 4

1.2.4 基于集成学习和贝叶斯推论的 KECA 模型 5

1.3 过程监测策略 8

1.4 TE 过程仿真研究 9

1.5 本章小结 13

图目录

图 1.1 两类数据分别在 1) 二维空间 2) 三维空间 1

图 1.2 径向基核函数曲线分布示意图 6

图 1.3 EKECA 算法流程图 8

图 1.4 TE 过程的工艺流程图 9

图 1.5 故障 4 的检测效果: (a) KECA ($c = 10m$); (b) KECA ($c=7000$); (c) EKECA 13

图 1.6 故障 5 的检测效果: (a) KECA ($c = 10m$); (b) KECA ($c=7000$); (c) EKECA 14

表目录

表 1.1 核函数类型 6

表 1.2 TE 过程的故障描述 10

表 1.3 TE 过程中的监测变量 11

表 1.4 三种方法的误报率 11

表 1.5 三种模型的故障检测率 12

第1章 基于集成学习和贝叶斯推论的改进核熵成分分析

摘要 故障检测是故障诊断的一个重要组成部分，通过对故障进行检测，可以有效地判断工业生产过程中是否有故障发生，从而便于展开故障分类、故障隔离及故障重构等。KECA 作为一种新的处理非线性的方法逐步地被引入到故障诊断领域，可以利用该方法实现故障检测。本章将集成学习和贝叶斯推论引入到核熵成分分析中，通过集成具有不同参数的学习算法，利用贝叶斯推论将这些算法的检测结果转化为概率的形式实现故障检测。本章提出的新方法在田纳西-伊斯曼过程（TE Process）上进行了应用，并与在相同条件下的单模型 KECA 进行检测效果对比，验证了本章提出的新方法对不同类型的故障均具有较好的检测效果，从而说明了新方法的可行性。

关键词 故障检测；非线性；集成学习；贝叶斯推论；KECA

1.1 引言

PCA 是一种广泛被使用的过程监测方法，该方法通过提取过程当中的主要成分来达到降维的目的，而这些主要成分则是通过数据的方差的大小来反映。然而，在提取主成分的过程中的前提条件是数据服从高斯分布并且假设过程为线性过程。这些前提条件使得 PCA 针对非线性过程实现过程检测时很难获得满意的监测效果，由此引入了核函数，利用核函数可以将原始的非线性的数据映射到一个高维甚至无限维的空间当中，此时的数据近似为线性。其效果如 1.1 所示。从图1.1中可以看出，在二维空间中不可分的两类数据，投影到




图 1.1 两类数据分别在 1) 二维空间 2) 三维空间

高维空间利用坐标轴旋转可以实现分类，也就是说利用核函数将数据投影到高维空间后可

以找到超平面将原来不可分的数据实现分类，这样就可以实现将非线性问题近似线性化。这就是 KPCA 的出发点，该方法也是最常见的一种处理非线性的方法。为了更好地将这种方法应用于过程监测当中来，Lee 等人提出了平方预测误差（SPE）的计算方法，由此， T^2 和 SPE 两个统计指标被用到 KPCA 当中来检测过程。然而，这两个统计指标的置信限计算方法都是假设输入数据服从高斯分布，但是考虑到过程的非线性这种假设在实际的生产过程当中并不能很好地被满足。Ge 等人将统计局部方法引入 KPCA 中，利用统计局部方法通过假设检验重新构造了两个检测指标，新的构造的检测指标能够较好的满足高斯分布，从而使得故障的检测率较高地提高。Samuel 等则是利用核密度估计（KDE）的方法计算监测指标的控制限，这也在一定程度上改善了监测质量，然而，这也是建立在一定的假设基础上的。但是 KPCA 应用于过程检测时，依旧需要满足的假设条件是数据服从高斯分布，该假设在实际的生产过程中是不可能满足的，而 KECA 则是从信息熵的角度出发，不再要求原始数据服从高斯分布，从而与 KPCA 相比有更好的检测效果。

KECA 的原理与 KPCA 有所不同，在 KPCA 中考虑到方差对应于数据的特征幅度变化方向，降维则是通过尽可能多的保留数据特征变化来实现，也就是要通过保留核矩阵最大的方差来实现；而 KECA 则是通过引入信息熵的概念，通过保留最大的信息熵来实现降维的目的。熵则是通过核矩阵利用 Parzen 窗实现其密度估计，此时，通过将数据投影到保留输入数据最大熵对应的核方向上实现了维度的降低。然而，在实际的生产过程中会存在不同类型的故障，利用单一的模型并不能够很好地实现对多类型故障的检测。此外，核参数的选择也会对故障的检测效果有重要的影响，恰当的核参数能够使得 KECA 对特定的故障有非常好的检测效果。

综合以上两方面的考虑，本章提出了利用集成学习通过将多个模型组合起来可以很好的避免由于单个模型选择有误造成的不好的结果，通过选择一系列的多样的能够满足不同故障检测效果核参数建立 KECA 的子模型，然后将这些子模型通过贝叶斯推论转化为概率的形式，再利用集成学习将这些模型组合起来。此时，检测效果好的模型会有一个较大的权重，这样，模型的监测效果会有较大的改善。这种情况下，不再需要原始数据及降维后的数据服从高斯分布，同时也降低了针对不同类型故障选择合适核参数时候的盲目性。

1.2 基于集成学习和贝叶斯网络的模型

1.2.1 KECA 模型介绍

KECA 是由特罗姆瑟大学教授 Robert Jenssen 在 2010 年提出的，该方法的出发点是信息熵，利用信息熵提取数据中的主成分，将熵最大的方向作为投影方向，从而实现了将高

维数据向低维的映射，通过对数据的空间变化达到了特征提取的目的。该方法也被广泛地应用于聚类、模式识别以及降低噪声等领域。Renyi 熵作为一种信息熵的指标，其计算公式为：

$$H(p) = -\log \int p^2(X) dX \quad (1.1)$$

其中， $p(X)$ 是样本 X 的概率密度函数， X 是中心化之后的样本数据。由于对数函数具有单调性，出于简化的目的，式1.1可以考虑为下式：

$$V(p) = \int p^2(X) dX \quad (1.2)$$

这样对于瑞利熵 $H(p)$ 的计算转化为对 $V(p)$ 的估计，在此引入 Parzen 窗概率密度估计算子

$$p(X) = \frac{1}{N} \sum_{i=1}^N k(X, X_i) \quad (1.3)$$

其中， $k(X, X_i)$ 就是 parzen 窗，也就是中心在 X_i 的核，其性质由参数 c 决定。由于 $p(X)$ 是密度函数，为了使得其具有较好的性质，那么， $k(X, X_i)$ 也必须满足是一种密度函数。也就是说此处的 parzen 窗可以看作是 Mercer 特征空间中的核函数。通过将公式 (1.3) 引入到公式 (1.2) 中可以得到：

$$\hat{V}(p) = \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N k(X_i, X_j) = \frac{1}{N^2} \mathbf{1}^T \mathbf{K} \mathbf{1}, \quad (1.4)$$

\mathbf{K} 是 $(N \times N)$ 的核矩阵， $\mathbf{1}$ 是 $(N \times 1)$ 的向量，并且向量中的所有元素都是 1。此时，核矩阵包含了瑞利熵估计中的所有的有效样本。再对核矩阵进行特征分解：

$$\mathbf{K} = \mathbf{E} \mathbf{\Lambda} \mathbf{E}^T, \quad (1.5)$$

\mathbf{E} 是分解之后的特征向量矩阵，矩阵中每一列为特征分解的特征向量 $\mathbf{e}_1, \dots, \mathbf{e}_N$ ， $\mathbf{\Lambda}$ 为其特征矩阵，该矩阵为对角矩阵，对角线上所有元素就是其对应的特征值 $\lambda_1, \dots, \lambda_N$ 。此时，公式 (1.4) 可以表示为

$$\hat{V}(p) = \frac{1}{N^2} \sum_{i=1}^N (\sqrt{\lambda_i} \mathbf{e}_i^T \mathbf{1})^2. \quad (1.6)$$

也就是说，瑞利熵可以表示为 N 个分量的累积，每一个分量都对熵的估计起一定的作用，而这个分量即包含了特征值又包含了特征向量。而当且仅当 $\lambda_i \neq 0$ 或 $\sqrt{\lambda_i} \mathbf{e}_i^T \mathbf{1} \neq 0$ 时候，该累积项才会对熵估计有贡献。这就是说，单独的特征值无论其值的大小并不能够保证对瑞利熵有一个较大的贡献值。

1.2.2 KECA 的优势

KECA 与 KPCA 是两种比较相似的数据转换方法，但是两者却是从不同的角度出发的，KECA 具备一定的优势，其具体表现为：

(1) 信息熵角度出发

KECA 与 KPCA 相比一个优势就在于 KECA 不需要任何的假设前提。KPCA 是为了解决 PCA 针对非线性情况下监测效果恶化的问题，该方法依旧需要原始数据服从高斯分布的假设条件，而 KECA 则是从信息熵的角度出发，通过实现数据集的平均向量欧几里德长度的估计达到数据变换。而在实际的工业过程当中获得的数据并不是满足高斯分布，KECA 在原理上相较于 KPCA 更具有优势。

(2) 核矩阵中心化

在 KECA 将数据映射到特征空间后，核矩阵并不需要中心化，因为核矩阵的中心化意味着 $m = \frac{1}{N} \sum \Phi(X) = 0$ ，而 $\hat{V}(p) = \|m\|^2 = 0$ ，那么，瑞利熵的估计 $\hat{H}(p) = \infty$ ，输入空间的瑞利熵的估计值为无穷大。由此，针对大规模数据时，该方法在实现过程中可以减少计算量。

(3) 角结构

KECA 方法在将数据映射的过程中，投影后的数据会有一个很明显的角结构，这就使得数据经过 KECA 后能够更好地区分开来，而 KPCA 并不具备这样的能力。

1.2.3 基于 KECA 的非线性过程监测

在 KECA 中，核矩阵并不需要中心化，当将其用于过程检测当中时，原始数据的主成分可以通过下面的公式实现提取：

$$\mathbf{T} = \mathbf{KE}. \quad (1.7)$$

通常情况下， T^2 和平方预测误差 (SPE) 两个统计量被用来作为过程监测的统计指标，这两个指标同样适用于本章中 KECA 方法，可以用他们分别来反映模型内外部的变化。其中， T^2 用马氏距离计算投影后向量的标准平方和来表征模型的主，可以用它来反映每个采样点在幅值以及变化趋势上与模型的偏离程度；SPE 则是采用欧式距离反映每个采样点在幅值以及变化趋势上与模型之间的误差。其定义形式如下所示：

$$T^2(i) = [t_{i1}, \dots, t_{ip}] \Lambda_p^{-1} [t_{i1}, \dots, t_{ip}]^T, \quad (1.8)$$

其中 Λ_p^{-1} 是主成分所对应的特征值所组成的对角矩阵的逆, p 是主成分的个数, N 是采样点数, T^2 的控制限可以通过 F 分布来实现估计。

$$T_{p,N,\alpha}^2 \sim \frac{p(N-1)}{N-p} F_{p,N-p,\alpha}. \quad (1.9)$$

SPE 则是通过下面的公式来计算:

$$SPE(i) = \sum_{j=1}^{n_0} t_{ij}^2 - \sum_{j=1}^p t_{ij}^2, \quad (1.10)$$

其中 n_0 代表特征空间的维数, p 是主成分的个数, 其控制限可以通过近似分布计算得到:

$$SPE_\alpha = g\chi_h^2, \quad (1.11)$$

其中 g, h 分别代表 SPE 的幅度和自由度, 设 a 是其均值的估计值, b 是其方差的估计值, 则有 $g = b/2a$ 和 $h = 2a^2/b$ 。

1.2.4 基于集成学习和贝叶斯推论的 KECA 模型

将 KECA 引入到过程监测当中能够较好地解决非线性问题, 然而, 在 KECA 方法中由于核函数的存在, 使得监测效果依赖于核函数的参数选择, 到目前为止没有明确的参数选择方法, 与此同时, 在工业生成过程中存在不同类型的故障, 单一的 KECA 模型并不能有效地针对所有类型的故障都具有很好地检测效果。而集成学习可以有效地解决这个问题。集成学习用于分类时候常见的方法有以下四种:

(1) 通过处理训练数据

该种类型的集成包括装袋 (bagging) 和提升 (boosting), 通过对同一个样本空间利用不同的抽样方式进行选择, 获得不同的分类效果, 然后将这些不同的分类效果集成。

(2) 通过处理输入特征

该方法则是通过选择输入特征的子集从而形成不同的训练集, 在选择特征集的时候既可以通过随机的方法选取也可以利用专家知识选取, 该方法对于包含大量冗余特征的数据集具有很好的分类效果。

(3) 通过处理类标号

该方法的出发点就是将多类问题利用类标号随机的划分为两个不相交的类从而转化为二分类问题, 通过多次这样的划分在利用投票的方式实现了集成分类。(4) 通过处理学习算法

该方法与以上的几种方法不相同，该方法是针对相同的训练集多次执行算法得到不同的模型，然后将这些模型的分类效果集成。

本章所选择的集成方法就是通过集成学习算法来实现的，在 KECA 中，其核函数可以有多种不同的类型，如下表所示：由于 RBF 核函数在一定条件下可以转换为多项式核函

表 1.1 核函数类型

核函数类型	核函数表达式
多项式核函数 (polynomial)	$\mathbf{K}(\mathbf{x}, \mathbf{y}) = (\theta + \mathbf{x} \cdot \mathbf{y})^d$
径向基核函数 (RBF)	$\mathbf{K}(\mathbf{x}, \mathbf{y}) = \exp(-\ \mathbf{x} - \mathbf{y}\ ^2 / 2\sigma^2)$
Sigmoid 核函数	$\mathbf{K}(\mathbf{x}, \mathbf{y}) = \tanh[-v(\mathbf{x} \cdot \mathbf{y}) + c]$

数及 Sigmoid 核函数，在此，选择 RBF 核函数作为 KECA 的核函数。为了简化将核函数表示为：

$$\mathbf{K}(\mathbf{x}, \mathbf{y}) = \exp(-\|\mathbf{x} - \mathbf{y}\|^2 / c), \quad (1.12)$$

其中，核函数的性质完全由其参数 c 决定。其参数核密度曲线与其核参数的关系如图1.2所示。




图 1.2 径向基核函数曲线分布示意图

而不同类型的故障需要不同核参数使得其检测效果最佳，在本章中考虑选择一系列的核参数建立对应的模型，利用相同的训练数据训练这些模型，再将这些模型的检测效果利用贝叶斯推论转化为概率的形式集成起来，从而实现了对不同类型的故障均有较好的检测效果，同时，也避免了核参数选择的问题。因此，这一系列的核参数的范围必须有足够的广度，能够适用于不同类型的故障，我们选择了如下的 B 组参数：

$$c_i = 2^{(i-1)} \times 5m \quad i = 1, \dots, B. \quad (1.13)$$

m 表示训练数据的维数, B 表示模型的数目, 当 B 选择恰当时候核参数具有比较大的范围, 能够较好的满足不同类型的故障的需求。因此, 不同核参数的模型对应的核矩阵特征分解可表示为:

$$\mathbf{K}^{(i)} = \mathbf{E}^{(i)} \Lambda^{(i)} \mathbf{E}^{(i)T}. \quad (1.14)$$

其相对应的检测结果可表示为:

$$\mathbf{T}^{(i)} = \mathbf{K}^{(i)} \mathbf{E}^{(i)}. \quad (1.15)$$

再通过 T^2 和 SPE 可以利用每一个子模型对新的样本数据 \mathbf{x} 进行检测, 然后通过贝叶斯推论将其转化为故障概率的形式:

$$P_{T^2}^{(i)}(F|\mathbf{x}) = \frac{P_{T^2}^{(i)}(\mathbf{x}|F)P_{T^2}^{(i)}(F)}{P_{T^2}^{(i)}(\mathbf{x})}, \quad (1.16)$$

$$P_{SPE}^{(i)}(F|\mathbf{x}) = \frac{P_{SPE}^{(i)}(\mathbf{x}|F)P_{SPE}^{(i)}(F)}{P_{SPE}^{(i)}(\mathbf{x})}, \quad (1.17)$$

分母中的 $P_{T^2}^{(i)}(\mathbf{x})$ 和 $P_{SPE}^{(i)}(\mathbf{x})$ 可以通过全概率进行计算:

$$P_{T^2}^{(i)}(\mathbf{x}) = P_{T^2}^{(i)}(\mathbf{x}|N)P_{T^2}^{(i)}(N) + P_{T^2}^{(i)}(\mathbf{x}|F)P_{T^2}^{(i)}(F), \quad (1.18)$$

$$P_{SPE}^{(i)}(\mathbf{x}) = P_{SPE}^{(i)}(\mathbf{x}|N)P_{SPE}^{(i)}(N) + P_{SPE}^{(i)}(\mathbf{x}|F)P_{SPE}^{(i)}(F), \quad (1.19)$$

其中 N 和 F 分别代表了正常和故障情况, $p(N)$ 和 $p(F)$ 是正常和故障情况下的先验概率。当显著水平设为 α , $p(N)$ 的值此时就是 α , $p(F)$ 的值则是为 $1 - \alpha$ 。为了计算故障概率的大小, 条件概率 $P_{T^2}^{(i)}(\mathbf{x}|N)$, $P_{T^2}^{(i)}(\mathbf{x}|F)$, $P_{SPE}^{(i)}(\mathbf{x}|N)$, 和 $P_{SPE}^{(i)}(\mathbf{x}|F)$ 被定义为如下的形式:

$$P_{T^2}^{(i)}(\mathbf{x}|N) = \exp(-T^{2(i)}/T_{limit}^{2(i)}), \quad (1.20)$$

$$P_{SPE}^{(i)}(\mathbf{x}|N) = \exp(-SPE^{(i)}/SPE_{limit}^{(i)}), \quad (1.21)$$

$$P_{T^2}^{(i)}(\mathbf{x}|F) = \exp(-T_{limit}^{2(i)}/T^{2(i)}), \quad (1.22)$$

$$P_{SPE}^{(i)}(\mathbf{x}|F) = \exp(-SPE_{limit}^{(i)}/SPE^{(i)}), \quad (1.23)$$

上式中的 $T_{limit}^{2(i)}$ 和 $SPE_{limit}^{(i)}$ 分别代表第 i 个模型的控制限。通过权重组合的方式可以将故障的概率指标表示为如下形式:

$$ET_{new}^2 = \sum_{i=1}^{n_s} \frac{P_{T^2}^{2(i)}(F|\mathbf{x})}{\sum_{j=1}^{n_s} P_{T^2}^{(j)}(F|\mathbf{x})}, \quad (1.24)$$

$$ESPE_{new} = \sum_{i=1}^{n_s} \frac{P_{SPE}^{2(i)}(F|\mathbf{x})}{\sum_{j=1}^{n_s} P_{SPE}^{(j)}(F|\mathbf{x})}. \quad (1.25)$$

此时, 显著水平 α 扮演了控制限的作用, 当 $ET_{new}^2 < \alpha$ 和 $ESPE_{new} < \alpha$ 时候, 认为系统处于正常工况状态, 当 $ET_{new}^2 > \alpha$ 或者 $ESPE_{new} > \alpha$ 的时候, 则认为系统有检测到故障。

1.3 过程监测策略

我们将上一节所介绍的方法称为 EKECA，利用 EKECA 实现故障检测的具体流程可以分为离线建模和在线监测两部分，该算法的流程图如图1.3所示，而具体实现为：

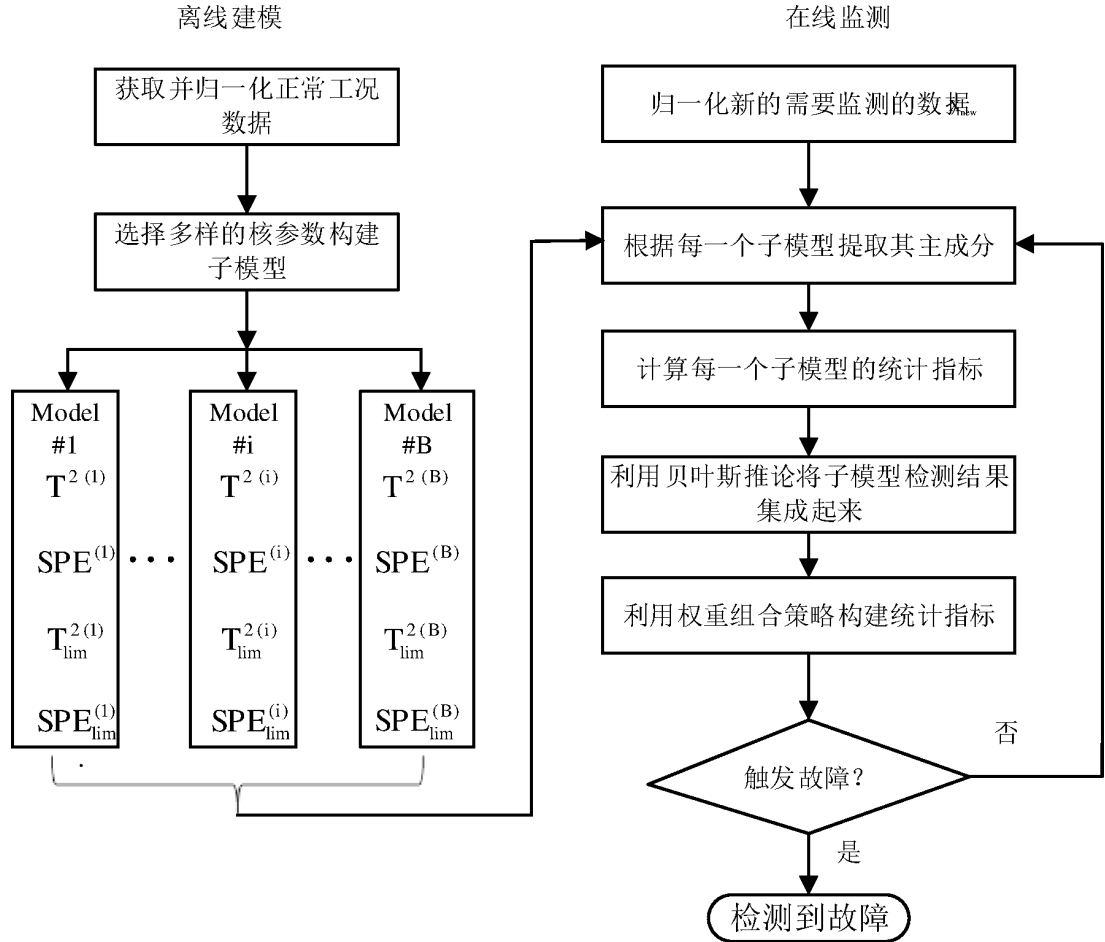


图 1.3 EKECA 算法流程图

离线建模：

- (1) 采集正常工况状态下的生产数据，经过标准化之后作为训练集 \mathbf{X} ；
- (2) 针对每一个核函数，构造 KECA 模型并通过 $\|\mathbf{e}_i\|^2 = 1/(N\lambda_i)$ 归一化其负载矩阵

\mathbf{E} ；

- (3) 通过 $\mathbf{T}^{(i)} = \mathbf{KE}^{(i)}$ 提取每一个子模型中的主成分信息；
- (4) 计算每一个子模型中的统计指标 T^2 和 SPE 以及相对应的控制限。

在线监测：

- (1) 采用与离线阶段相同的方法归一化在线数据 \mathbf{x}_{new} ；

- (2) 通过 $\mathbf{t}_k^{(i)} = \mathbf{K}_{new}^{(i)} \mathbf{e}_k^{(i)}$, $k = 1, \dots, p^{(i)}$ 提取 \mathbf{x}_{new} 的主成分部分;
- (3) 将每一个子模型的检测效果通过贝叶斯推论转化成概率的形式并将他们集成起来;
- (4) 判断是否有故障发生, 其中 $ET_{new}^2 < \alpha$ 并且 $ESPE_{new} < \alpha$ 过程处于正常状态, 而 $ET_{new}^2 > \alpha$ 或者 $ESPE_{new} > \alpha$ 则代表检测到了故障。

1.4 TE 过程仿真研究

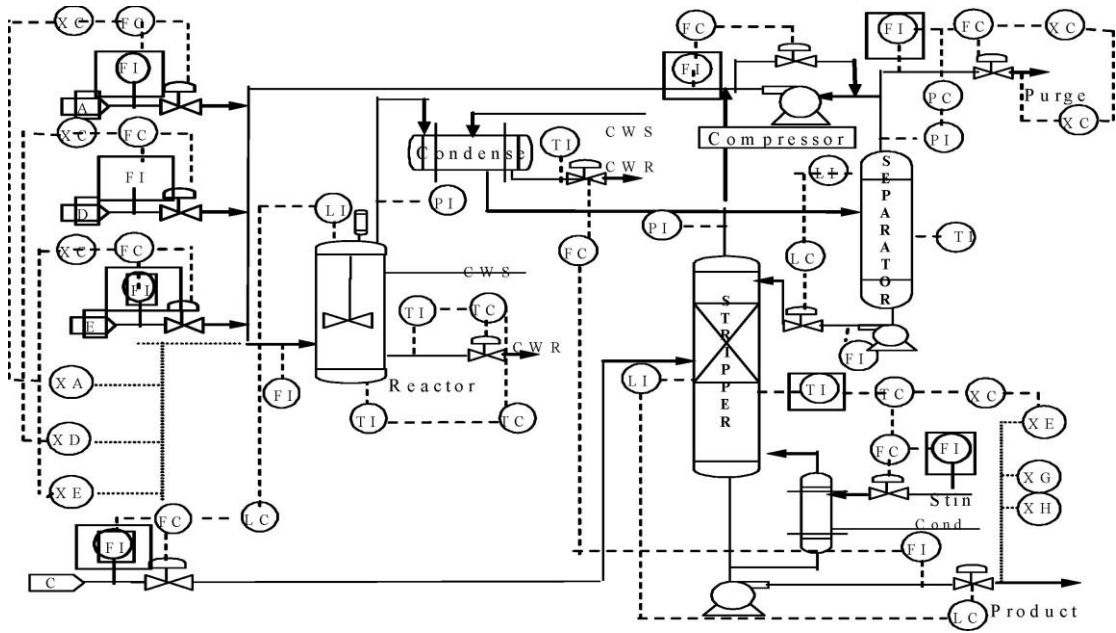




图 1.4 TE 过程的工艺流程图

田纳西伊斯曼 (Tennessee Eastman, TE) 过程是一个被广泛使用的并且基于真实工业生产过程的仿真平台。许多学者使用该平台来测试其算法的有效性并进行相应的评估, 该仿真平台的闭环结构如图1.4 所示。它包含五个主要的操作部分, 分别是: 反应器、冷凝器、分离器、解析塔以及压缩机。4 种气体反应物 (A、C、D、E) 经过反应生成 2 种液体产物 (G 和 H), 此外, 该过程还包含了 1 种副产物 (F) 及惰性气体 (B), 其中, B 未直接参与反应。整个过程的化学方程式如下所示:



在整个反应过程中伴随着热量的变化, 利用冷凝水实现热量的转移。其具体过程可参考相应文献。TE 过程中包含着 41 个测量变量和 12 个操作变量以及 21 个故障, 故障的详细信息如下表所示: 本章中选择了 22 个连续变量和 11 个操作变量 (除了搅拌速率) 来模拟反

表 1.2 TE 过程的故障描述

序号	故障描述	类型
1	A/C 进料流量比, B 含量保持不变	阶跃变化
2	B 含量变化, A/C 进料流量比保持不变	阶跃变化
3	D 进料温度变化	阶跃
4	反应器冷却水入口温度变化	阶跃变化
5	冷凝气冷却水入口温度变化	阶跃变化
6	A 进料不足	阶跃变化
7	C 注入压力不足	阶跃变化
8	A、B、C 三种投料比变化	随机变化
9	D 进料温度变化	随机变化
10	C 进料温度变化	随机变化
11	反应器冷却水入口温度发生变化	随机变化
12	冷凝器冷却水入口温度发生变化	随机变化
13	流程动力常数偏移	缓慢漂移
14	反应器的冷却水阀口工作不正常	粘滞型
15	冷凝器的冷却水阀口工作不正常	粘滞型
16	未知	未知
17	未知	未知
18	未知	未知
19	未知	未知
20	未知	未知
21	C 进料口处阀口卡死	停滞位置

应过程, 故障信息见表1.3所示。其中, 训练数据为正常工况下的数据 (包含 500 个样本), 所有故障数据在非正常工况下采集 (包含 960 个样本), 所有数据的采样间隔均为 3 分钟, 且故障是在第 161 个点也就是在正常工况 8 小时之后引入故障。本章的 TE 仿真当中, 共选取了 11 个 KECA 子模型, 也就是 $B = 11$, 此外, 选取了两个 KECA 的模型用来多对比, 其核参数分别是 $c = 10m$ 和 $c = 7000$, 在所有的模型当中用来计算 T^2 和 SPE 的成分

表 1.3 TE 过程中的监测变量

序号	变量名称	序号	变量名称	序号	变量名称
1	A 流量	12	气液分离器液位	23	D 进料量
2	D 流量	13	气液分离器压力	24	E 进料量
3	E 流量	14	汽提塔分离器出口流量	25	A 进料量
4	总进料流量	15	汽提塔液位	26	总进料量
5	压缩机返回物料流量	16	汽提塔压力	27	压缩机再循环阀
6	反应器給料流量	17	汽提塔出口流量	28	排放阀
7	反应器压力	18	汽提塔温度	29	分离器罐液流量
8	反应器液位	19	汽提塔蒸汽流量	30	汽提塔液体产品流量
9	反应器温度	20	压缩机功率	31	汽提塔水流阀
10	排空物料流量	21	反应器冷凝液出口温度	32	反应器冷水流量
11	气液分离器温度	22	冷凝器冷凝液出口温度	33	冷凝器冷却水流量

的个数分别为 15 和 20，所有的置信水平为 99%。

表 1.4 三种方法的误报率

Statistics	KECA($c = 10m$)	KECA($c = 10m$)	EKECA
T^2	0.0638	0.0675	0.0700
SPE	0.0088	0.0088	0.0250

为了说明 EKECA 方法的可行性，对正常工况下的数据进行监测，其监测效果如表 1.4 所示，这三种方法的误报率均比较低，从而验证了这三种方法的有效性。21 种故障的检测率如表 1.5 所示，其中检测效果最好的部分用黑体标了出来。从表中的仿真结构不难看出，EKECA 与单独参数的 KECA 相比能够有效地检测大部分故障（故障 3，9，15 为缓变故障，至今几乎所有算法均没有好的检测效果），且对某些故障有着非常好的检测效果。以故障 4 和故障 5 为例，故障 4 是阶跃型的故障，由表 1.2 可知，该故障影响反应器的冷却水的温度变化，从图 1.5 中可以看出，在冷却水的温度变化发生变化时候，EKECA 可以有效地检测出该变化，而另外两个模型并不能连续地检测出来，这是因为 TE 过程是一个闭环系统，当温度发生变化时候，其闭环的作用掩盖了故障的存在，使得单核参数的 KECA 算法误认为该故障已经消失，其统计指标在控制限上下来回震荡。而 EKECA 则通过不同类型的参数的集成，能够有效地识别这个存在于闭环中的阶跃故障，在 161 个采样点之后，

表 1.5 三种模型的故障检测率

故障类型	KECA($c = 10m$)		KECA($c = 7000$)		EKECA	
	T^2	SPE	T^2	SPE	T^2	SPE
1	0.8125	0.0188	0.9925	0.9925	0.9975	0.9975
2	0.0275	0.0038	0.9825	0.9838	0.9850	0.9813
3	0.1350	0.0238	0.1600	0.0250	0.1700	0.0663
4	0.2813	0.9275	0.3438	0.1650	0.9713	0.9125
5	0.3200	0.0988	0.3638	0.2338	1	1
6	0.0138	0	1	0.9975	1	1
7	0.4788	0.0425	0.9575	0.9950	0.9963	0.9775
8	0.7888	0.3525	0.9688	0.9638	0.9825	0.9825
9	0.1075	0.0250	0.1213	0.0138	0.1475	0.0650
10	0.5425	0.1113	0.7250	0.2325	0.8338	0.8875
11	0.4250	0.4050	0.4763	0.3413	0.7050	0.6225
12	0.7763	0.1725	0.9875	0.9588	0.9975	0.9988
13	0.4175	0.2438	0.9438	0.9238	0.9513	0.9550
14	0.7075	0.4238	0.9300	0.9575	0.9838	0.9988
15	0.1813	0.0313	0.1750	0.0200	0.2075	0.0725
16	0.4150	0.1275	0.9200	0.2850	0.9325	0.8363
17	0.3588	0.4913	0.8438	0.7625	0.9338	0.9575
18	0.0425	0.0300	0.8975	0.8863	0.9100	0.9075
19	0.0863	0.0350	0.7963	0.0438	0.7863	0.6588
20	0.5138	0.3225	0.7550	0.3438	0.7263	0.7788
21	0.3500	0.5563	0.3738	0.3588	0.4100	0.5413

两个统计指标均一直处于控制限的上方，实时地显示故障并没有消失。故障 5 的检测效果如图 1.6 所示，同样从表 1.2 可知，故障 5 位冷凝器冷却水入口温度变化所引起的阶跃故障，在第 350 个采样点之后闭环有效地掩盖了故障存在的事实，使得两个单核参数 KECA 都认为故障已经消失，生产过程恢复正常工况，其统计指标均已处于控制限的下方。而 EKECA 此时依旧能够清晰地指出故障存在的事实，其统计指标均始终处于控制限的上方。EKECA 不仅能够针对不同类型的故障均具备较好的检测效果，对于特定类型的故障，

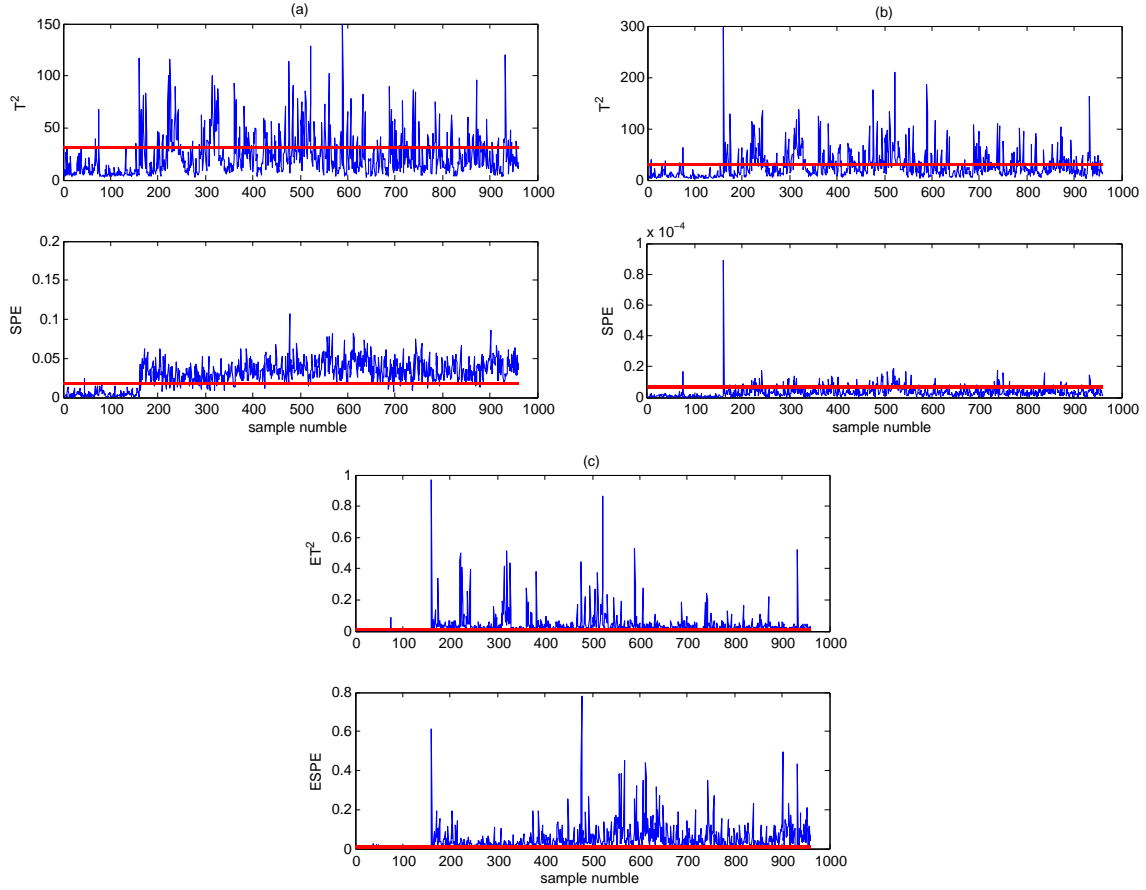


图 1.5 故障 4 的检测效果: (a) KECA ($c = 10m$); (b) KECA ($c=7000$); (c) EKECA

EKECA 能够有效地持续地检测到故障的存在。

1.5 本章小结

针对工业过程中数据的非线性，本章提出了基于集成学习和贝叶斯推论的 KECA 检测方法 EKECA。在 TE 平台上，该方法的仿真结果证实了 EKECA 相比于单核参数的 KECA 能够针对不同类型的故障均具备较好的检测效果，对于特定类型的故障也能够有效地持续地检测到故障的存在，可以得到这样的结论：EKECA 的故障检测效果优于单模型的 KECA。另一方面，该方法也通过集成的手段避免了引入核函数带来的核参数选择难题。同时，使用该方法选择主成分的个数是少于 KPCA 的，这也使得该方法在处理非线性检测时候速度要优于 KPCA。此外，由于该方法的集成性，使得它更能满足未知故障的检测。

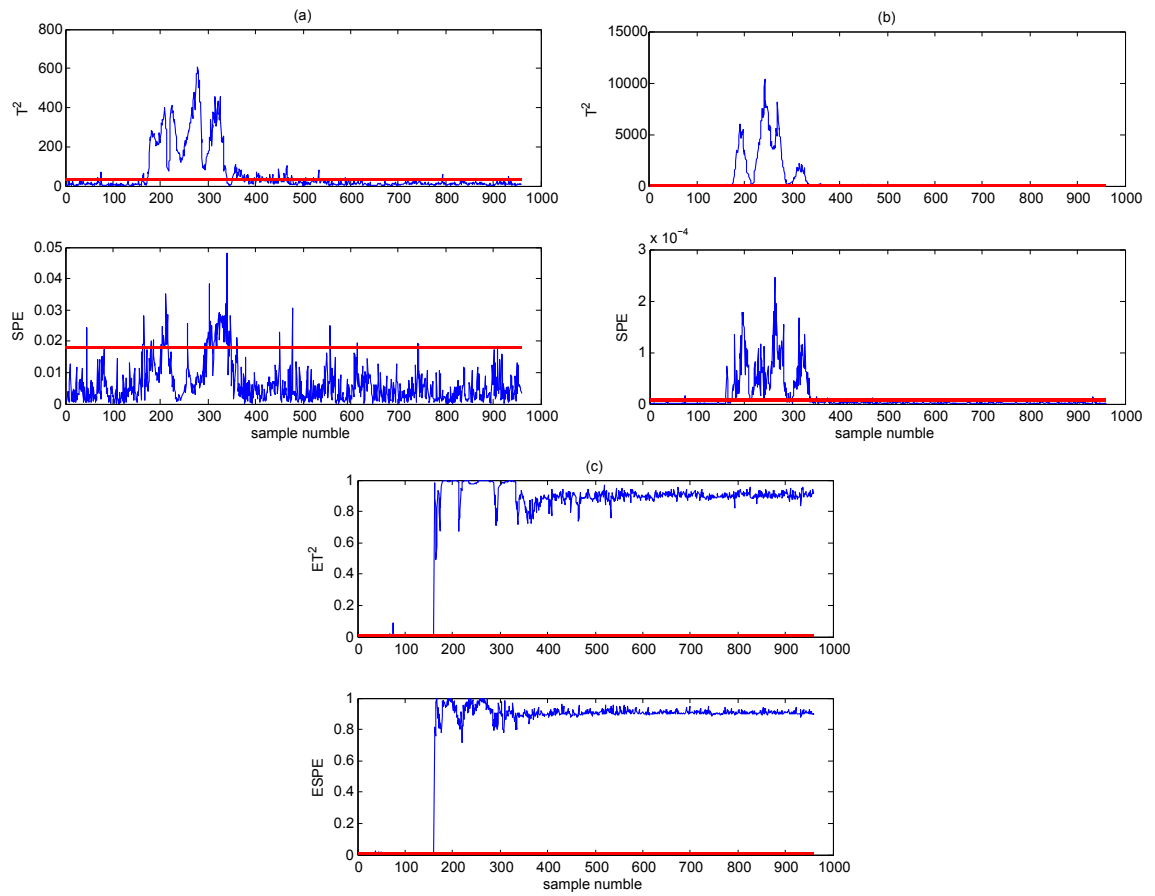


图 1.6 故障 5 的检测效果: (a) KECA ($c = 10m$); (b) KECA ($c=7000$); (c) EKECA